

Sprawozdanie II

Wykonał Michał Wawrentowicz, Data Science

1. Opis problemu:

Celem zadania było przeprowadzenie analizy danych dotyczących chorób serca oraz zbudowanie modelu klasyfikacyjnego opartego na regresji logistycznej. Model miał przewidywać występowanie choroby serca na podstawie danych medycznych pacjentów.

Wykorzystano zbiór danych „Heart Disease” zawierający informacje medyczne pacjentów, takie jak:

- wiek (age)
- płeć (sex)
- ból w klatce piersiowej (cp)
- ciśnienie spoczynkowe (trestbps)
- poziom cholesterolu (chol)
- maksymalne tętno (thalach)

Zmienna docelowa (target) początkowo miała wartości wieloklasowe (0–4), ale została przekształcona do problemu zerojedynekowego:

- 0 = brak choroby
- 1 = obecność choroby

2. Analiza danych:

W ramach analizy sprawdzono strukturę danych, wykryto brakujące wartości, zbadano rozkłady zmiennych i przeanalizowano zależności między cechami.

Brakujące wartości zostały uzupełnione przy użyciu:

- mediany (dla danych liczbowych)
- wartości najczęstszej (dla cech kategorycznych)

3. Przygotowanie danych:

W ramach preprocessing wykonano:

- uzupełnianie braków danych (SimpleImputer)
- kodowanie zmiennych kategorycznych (OneHotEncoder)
- standaryzację danych (StandardScaler)
- podział na zbiór treningowy i testowy

4. Opis modelu:

Zastosowano algorytm regresji logistycznej, który modeluje prawdopodobieństwo przynależności do klasy 1.

Model opiera się na funkcji:

$$P(y = 1) = \frac{1}{1 + e^{-z}}$$

gdzie:

- z to kombinacja liniowa cech wejściowych,
- parametr C kontroluje siłę regularyzacji:
 - o małe $C \rightarrow$ silna regularyzacja (prostszy model),
 - o duże $C \rightarrow$ słabsza regularyzacja (bardziej dopasowany model).


5. Eksperymenty, wizualizacje:

Przeprowadzono eksperymenty dla różnych wartości parametru C :

- 0.01
- 0.1
- 1
- 10
- 100

Wyniki:

- $C = 0.01$, Accuracy = 0.8197
- $C = 0.1$, Accuracy = 0.8525
- $C = 1$, Accuracy = 0.8852
- $C = 10$, Accuracy = 0.8689
- $C = 100$, Accuracy = 0.8689



Wnioski:

Najlepszy wynik uzyskano dla C równego 1. ~88,5% accuracy to dobra skuteczność klasyfikacji. Zbyt małe C powoduje niedouczenie, a zbyt duże stabilizację wyników. Dodatkowo analiza krzywej ROC potwierdza dobrą jakość klasyfikatora, co oznacza, że model skutecznie rozróżnia klasy pozytywne i negatywne.

6. Podsumowanie

Przeprowadzono pełny proces analizy danych medycznych oraz budowy modelu klasyfikacyjnego opartego na regresji logistycznej. Można stwierdzić, że zastosowany model regresji logistycznej osiąga dobrą skuteczność w zadaniu klasyfikacji chorób serca. Najlepsze wyniki uzyskano dla parametru regularyzacji $C = 1$, co wskazuje na kompromis pomiędzy niedouczeniem a przeuczeniem modelu. Dokładność modelu wyniosła około 0.885, co świadczy o jego dobrej jakości predykcyjnej. Analiza krzywej ROC potwierdza zdolność modelu do poprawnego rozróżniania klas pozytywnej i negatywnej. Preprocessing danych miał istotny wpływ na poprawne działanie modelu. Podsumowując, regresja logistyczna okazała się skutecznym i stabilnym modelem dla tego zbioru danych, jednak dalsze ulepszenia mogłyby dodatkowo poprawić jakość klasyfikacji.